LeNet-5 卷积神经网络在 MNIST 数据集上的实验报告

作者： Manus AI
日期： 2026年3月30日

1. 实验目的

本实验旨在通过构建经典的 LeNet-5 卷积神经网络，实现对 MNIST 手写数字数据集的识别。在此基础上，采用控制变量法，分别对学习率（Learning Rate）、批大小（Batch Size）和优化器（Optimizer）三种关键超参数进行调整，探究不同参数设置对模型训练过程及最终识别率的影响。通过本实验，加深对卷积神经网络结构及深度学习模型调参的理解。

2. 网络结构与实验设置

2.1 LeNet-5 网络结构介绍

LeNet-5 是由 Yann LeCun 等人于 1998 年提出的一种早期且非常经典的卷积神经网络，最初被设计用于识别支票上的手写数字。在本实验中，网络输入为 28×28 的单通道灰度图像，具体结构如下：

层级名称	层类型	参数设置	输出尺寸
Input	输入层	单通道灰度图	$1 \times 28 \times 28$
C1	卷积层	6个 5×5 卷积核，步长 1，无填充	$6 \times 24 \times 24$
S2	池化层	2×2 平均池化，步长 2	$6 \times 12 \times 12$
C3	卷积层	16个 5×5 卷积核，步长 1，无填充	$16 \times 8 \times 8$
S4	池化层	2×2 平均池化，步长 2	$16 \times 4 \times 4$
Flatten	展平层	将多维特征图展平为一维向量	256
F5	全连接层	120 个神经元，ReLU 激活函数	120
F6	全连接层	84 个神经元，ReLU 激活函数	84
Output	输出层	10 个神经元（对应 0-9 类别）	10

2.2 实验环境与数据集

本实验要求使用 **MindSpore** 框架进行代码实现。数据集采用经典的 MNIST 手写字符数据集。为了加快实验迭代速度并进行多组参数对比，实验中选取了 5000 个样本作为训练集，1000 个样本作为测试集。所有图像在输入网络前均进行了归一化处理（均值 0.1307，标准差 0.3081）。

2.3 实验设计（控制变量法）

为探究不同参数对模型性能的影响，本实验采用控制变量法，设计了以下三组对比实验：

1. **学习率对比实验**：固定批大小为 32，优化器为 SGD，设置学习率为 0.001、0.01 和 0.1。
2. **批大小对比实验**：固定学习率为 0.01，优化器为 SGD，设置批大小为 16、32 和 64。
3. **优化器对比实验**：固定学习率为 0.01，批大小为 32，分别使用 `SGD`、`Adam` 和 `RMSprop` 优化器。

所有实验均训练 5 个 Epoch，并记录训练过程中的损失值、训练准确率和测试准确率。

3. 实验结果与分析

3.1 学习率（Learning Rate）对比实验

在固定批大小（32）和优化器（SGD）的条件下，不同学习率的实验结果如下表所示：

组别	学习率	训练时间 (s)	最终训练准确率	最终测试准确率
1	0.001	10.33	11.92%	13.60%
2	0.01	11.18	76.52%	65.40%
3	0.1	11.08	96.54%	96.00%

学习率对比

分析： 从结果可以看出，学习率对模型的收敛速度和最终性能有决定性影响。当学习率过小（0.001）时，模型在 5 个 Epoch 内几乎未能有效收敛，测试准确率仅为 13.60%；当学习率提升至 0.01 时，模型开始正常学习，准确率达到 65.40%；当学习率进一步提升至 0.1 时，模型快速收敛，取得了 96.00% 的优异测试准确率。这表明在当前有限的训练轮数内，较大的学习率有助于 SGD 优化器更快地跨越平缓区域，找到较好的局部最优解。

3.2 批大小（Batch Size）对比实验

在固定学习率（0.01）和优化器（SGD）的条件下，不同批大小的实验结果如下表所示：

组别	批大小	训练时间 (s)	最终训练准确率	最终测试准确率
1	16	13.63	88.46%	86.30%
2	32	11.23	84.12%	83.10%
3	64	8.86	64.74%	64.50%

批大小对比

分析： 批大小决定了每次参数更新所使用的样本数量。实验结果表明，较小的批大小（16）取得了最高的测试准确率（86.30%），而较大的批大小（64）准确率最低（64.50%）。这是因为在相同的 Epoch 数量下，较小的批大小意味着每个 Epoch 中参数更新的次数更多，从而加快了模型的收敛速度。此外，较小的批大小引入了更多的梯度噪声，这在一定程度上有

助于模型跳出局部最优。然而，较小的批大小也导致了单轮训练时间的增加（13.63s vs 8.86s）。

3.3 优化器（Optimizer）对比实验

在固定学习率（0.01）和批大小（32）的条件下，不同优化器的实验结果如下表所示：

组别	优化器	训练时间 (s)	最终训练准确率	最终测试准确率
1	SGD	10.56	79.50%	49.20%
2	Adam	12.22	97.32%	97.10%
3	RMSprop	11.66	94.60%	94.50%

优化器对比

分析： 优化器决定了梯度如何应用于参数的更新。实验结果显示，自适应学习率优化器（Adam 和 RMSprop）在相同条件下的表现远优于传统的 SGD 优化器。Adam 优化器取得了 97.10% 的最高测试准确率，RMSprop 紧随其后达到 94.50%，而基础的 SGD 仅有 49.20%。这是因为 Adam 和 RMSprop 能够根据历史梯度自动调整每个参数的学习率，从而在复杂损失曲面中实现更高效、更稳定的下降。虽然自适应优化器的计算复杂度略高，导致训练时间稍长，但其带来的收敛速度和精度提升是巨大的。

3.4 综合对比

综合对比

综合上述三组实验可以看出，对于当前的 LeNet-5 模型和 MNIST 数据集：

1. **Adam 优化器** 是提升模型性能的最有效手段之一。
2. 在使用基础 SGD 时，**适当提高学习率**（如 0.1）或 **减小批大小**（如 16）能够显著加快模型在有限轮数内的收敛。

4. 结论

本实验成功使用 MindSpore 框架实现了 LeNet-5 卷积神经网络，并在 MNIST 数据集上完成了训练与测试。通过严格的控制变量法实验，深入分析了学习率、批大小和优化器对模型性能的影响。

实验证明：

1. **学习率** 必须根据优化器和模型结构进行合理设置，过小导致收敛缓慢，适当增大可以加速收敛。
2. **批大小** 的选择需要在训练速度和泛化能力之间进行权衡，较小的批大小通常能带来更好的泛化性能和更快的收敛（按 Epoch 计）。
3. **自适应优化器**（如 Adam）在默认参数下通常比传统 SGD 表现出更强的鲁棒性和更快的收敛速度，是实际工程应用中的首选。

本次实验不仅验证了 LeNet-5 模型的有效性，也为后续复杂深度学习模型的超参数调优提供了宝贵的实践经验。